

F 题问题二：基于数据质量与领域配比的广义标度律建模

数学建模论文正文草稿（待参赛队核验）

2026 年 9 月 24 日

草稿使用说明：本文根据本次对话中已呈现的问题二模型、代码与实验图整理。文中的[待填：…]必须由参赛队从最终 results/ 文件提取真实数值后替换；图号为建议的论文插图位置，不代表本 PDF 已嵌入原实验图片。正式定稿前须核对官方题面、附件口径、每条模型公式与当前运行代码。本文不将半合成质量实验当作真实质量干预证据，也不把 A、B 两组的绝对 Loss 直接拼接。

2.1 问题分析与建模思路

大语言模型的训练性能受到模型参数规模、训练数据量、数据质量及训练领域配比等多种因素影响。经典标度律主要描述模型参数量和训练数据量与预测损失之间的关系，不能直接刻画质量和领域组成变化的影响。针对这一问题，本文以参数量—数据量标度律为基础，依次研究数据质量修正、领域配比相对效应及资源间的替代关系，建立具有明确适用边界的广义损失预测框架。

首先，使用 B1 训练轨迹建立经典标度律，并通过留一模型规模与后段 Token 阻断验证检验模型在同一数据体系内的预测能力。其次，使用 B7 质量实验比较不同质量响应函数，通过按 (N, D) 分组的嵌套交叉验证选择质量修正形式。随后，根据问题一建立的 A 组相对配比指数构造条件化配比接口，避免跨来源绝对 Loss 的直接相加。最后，基于选定模型研究边际效用、等损失曲线、质量提高 0.1 的等效参数量与固定基础算力下的参数—数据配置基准。

2.2 数据来源、计量口径与基本假设

2.2.1 数据来源与口径

B1 提供不同参数规模模型的训练轨迹，包含参数量 N 、累计训练 Token 数 D 及相应验证损失 L ，用于经典标度律的主要估计与内部验证。B7 提供不同 N, D, Q 条件下的半合成质量实验，用于研究 B7 评分尺度上的质量修正；B6 是 B7 的子集，不作为另一份独立训练样本重复计数。B4、B5 用于对不同模型族及来源进行留出检验。问题一的 A 组实验用于定义领域配比的相对效应指标，不直接与 B 组的绝对 Loss 合并。

本文以**十亿参数**作为 N 的数值单位、以**十亿 Token**作为 D 的数值单位。参数 A, B 的数值依赖这一单位约定；代入其他单位前必须一致换算。A、B 两组的验证集合、分词器及 Loss 聚合口径尚未证明相同，故同名

的 Loss 字段不构成可直接合并的依据。问题一综合质量分与 B7 的 Q_score 也没有可验证的共同标定锚点, 本文只在 B7 的评分尺度上估计质量响应。

2.2.2 基本假设

- (1) 在研究的数据范围内, 模型参数量和训练 Token 数对验证损失可由连续、单调递减的经验幂律近似; 该假设需由验证数据检验。
- (2) B7 质量评分在其定义范围内具有可建模的预测响应, 但该响应不预先视为真实训练质量干预的因果效应。
- (3) 不同训练检查点与同一 (N, D) 条件下的不同质量档位存在相关结构, 模型评价和不确定性估计应以相应实验组为划分与重抽样单位。
- (4) A 组领域配比模型可提供相对排序信息, 但其效应幅度不能在缺少共同标定的情况下直接作为 B 组的绝对 Loss 系数。

2.3 经典参数量—数据量标度律

2.3.1 模型建立

令模型参数量为 N 、累计训练 Token 数为 D 、验证交叉熵损失为 L 。采用经典经验标度律

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta} \quad (1)$$

其中, E 为极限损失项; A, B 分别为参数规模项与数据量项的系数; α, β 为标度指数。当 $A, B, \alpha, \beta > 0$ 时,

$$\frac{\partial L_0}{\partial N} = -\alpha AN^{-\alpha-1} < 0, \quad \frac{\partial L_0}{\partial D} = -\beta BD^{-\beta-1} < 0. \quad (2)$$

同时, 两个变量对应的二阶偏导数均为正, 说明在此模型内, 单独增加 N 或 D 时绝对损失改善具有边际递减特征。该性质是模型形式推导, 不代替跨体系的真实实验验证。

2.3.2 参数估计

记待估参数为 $\theta = (E, A, \alpha, B, \beta)$ 。为降低较大残差对拟合结果的影响, 考虑在对数 Loss 空间构造残差:

$$r_i(\theta) = \log \hat{L}_i(\theta) - \log L_i. \quad (3)$$

采用带边界、多初始点的稳健非线性最小二乘, 最小化 Huber 目标函数:

$$\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^n \rho_{\delta}(r_i(\theta)), \quad \rho_{\delta}(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta, \\ \delta(|r| - \frac{1}{2}\delta), & |r| > \delta. \end{cases} \quad (4)$$

对不同起点的候选解，应按同一 Huber 目标函数值而非另一个平方误差指标选择最终参数。正式实现使用何种目标、转折尺度、边界及最终点估计，应以最新模型参数文件为准。

2.3.3 训练轨迹划分与验证

同一规模模型的相邻训练检查点并非独立样本。本文以完整参数规模轨迹为基本留出单位：每次留出一个参数规模，使用其余规模估计模型，再预测留出规模的全部检查点。另在每个规模的轨迹上用较早阶段训练数据拟合，以后段 Token 记录检验沿训练进程的预测能力。随机行划分仅作为可能产生乐观结果的诊断，不作为主要泛化证据。

采用 MAE、RMSE、 R^2 、Spearman 相关系数和平均预测偏差联合评价。表 1 汇总最终实际输出；预测—观测散点图建议使用正式图 q2_02_classic_holdout。

验证任务	样本数	MAE	RMSE	R^2	Spearman
留一参数规模	[待填]	[待填]	[待填]	[待填]	[待填]
后段 Token	[待填]	[待填]	[待填]	[待填]	[待填]

图示表明，B1 范围内留一规模及后段 Token 的预测值与观测值较接近。但这只能支持 **B1 数据体系内** 的规模预测能力，不能由此推定其他模型族、分词器或验证集的绝对 Loss 同样适用该参数组。

2.4 数据质量修正的广义标度律

2.4.1 质量变量引入

设 B7 定义的质量评分为 $Q \in [0, 1]$ 。以经典模型的可约损失为基础，考虑质量乘子

$$g(Q) = 1 + \kappa(1 - Q), \quad \kappa \geq 0, \quad (5)$$

得到质量修正标度律

$$L_Q(N, D, Q) = E + (AN^{-\alpha} + BD^{-\beta})[1 + \kappa(1 - Q)]. \quad (6)$$

当 $Q = 1$ 时，式 (6) 形式上退化为经典标度律。但这里的 $Q = 1$ 是所用质量模型的参考规范化约定，不表示 **B1 训练语料** 已被真实测量为质量 1。若 $\kappa > 0$ ，则在这一经验模型内部

$$\frac{\partial L_Q}{\partial Q} = -\kappa(AN^{-\alpha} + BD^{-\beta}) < 0. \quad (7)$$

式 (7) 描述模型预测意义上的质量响应，不直接构成真实质量提升的因果结论。

2.4.2 候选模型及选择程序

为检验质量响应形式，比较无质量项、加性修正、可约项线性修正、可约项幂次修正、参数项修正及有效数据量修正等候选模型。B7 的数据划分以 (N, D) 组为单位，使同一组下的全部质量档位共同进入训练或验证部分，避免同组信息穿越划分边界。

在此基础上，采用外层五折、内层四折的分组嵌套验证：内层完成候选模型选择与参数估计，外层评价整个选模流程。在现有实验图中，不加入 Q 的模型误差高于所选质量修正模型；正式误差差值及外层评价指标需要由 `q2_quality_nested_metrics.csv` 等最终工件填写。图 `q2_04_quality_model_comparison` 为候选模型比较，图 `q2_05_quality_oof_diagnostics` 和图 `q2_12_nested_residuals` 可分别支持总体与分层残差讨论。

质量建模方案	分组验证 RMSE	模型角色
无 Q 的经典模型	[待填]	消融对照
可约项线性修正	[待填]	选定候选模型
其他质量修正模型	[待填]	结构比较
全流程嵌套验证	[待填]	对模型选择流程的外层评价

现有修订流程保留可约项线性修正作为主质量模型。然而，B7 是半合成数据，B6 → B7 新增质量档位验证也属于共享 (N, D) 条件下的质量插值，不能称为新来源的独立真实训练实验；B7 上的预测增益应被限定为该数据生成体系内的经验结果。

2.5 领域配比的相对效应与跨来源桥接

记 17 个训练领域的配比向量为

$$\mathbf{p} = (p_1, \dots, p_{17}), \quad p_j \geq 0, \quad \sum_{j=1}^{17} p_j = 1. \quad (8)$$

问题一提供了由领域配比预测 13 个验证域 Loss 的模型。为了避免直接拼接 A、B 两组不同口径的绝对损失，本文首先在 A4 参考数据内对各验证域预测 Loss 做标准化，聚合并调整方向，构造相对配比指数 $R_A(\mathbf{p})$ ，使其数值增大对应 **A 组模型预测的相对 Loss 降低**。借助 A 组不同规模的配方测试，使用 Spearman 相关系数检验该指数与相对性能之间的排序关系。

需注意，以上配比排序证据来自 A 组；其中部分测试集已在问题一中使用，因此不将其称作第二问全新的独立盲测。该指数也不是未经校准即可用于 B 组绝对 Loss 的回归系数。

为讨论可能的联合响应，可写出条件化情景模型

$$L_{\text{scenario}} = E + (AN^{-\alpha} + BD^{-\beta})[1 + \kappa(1 - Q)] \exp[-\eta_p R_A(\mathbf{p})]. \quad (9)$$

其中 η_p 为将 A 组相对配比指数转换为 B 组 Loss 效应的幅度参数。现有 B 组数据缺乏足够的独立配比变化和跨来源标定锚点，故 η_p 尚未识别。主模型取 $\eta_p = 0$ ，只依赖 N, D, Q ；非零 η_p 仅用于显式声明假设的条件情景，不应被表述为数据已估计出的真实效应，也不应由此宣称存在经过真实联合实验验证的四变量标度律。

2.6 资源边际效用与弹性

令 $R(N, D) = AN^{-\alpha} + BD^{-\beta}$ ， $g(Q) = 1 + \kappa(1 - Q)$ 。则主模型为 $L_Q = E + R(N, D)g(Q)$ ，其一阶偏导数为

$$\begin{aligned} \frac{\partial L_Q}{\partial N} &= -\alpha AN^{-\alpha-1}g(Q), \\ \frac{\partial L_Q}{\partial D} &= -\beta BD^{-\beta-1}g(Q), \\ \frac{\partial L_Q}{\partial Q} &= -\kappa R(N, D). \end{aligned} \quad (10)$$

可用负偏导数表示各变量增加时的局部 Loss 改善。进一步定义以 Loss 为分母的相对改善弹性：

$$\varepsilon_N = -\frac{N}{L_Q} \frac{\partial L_Q}{\partial N}, \quad \varepsilon_D = -\frac{D}{L_Q} \frac{\partial L_Q}{\partial D}, \quad \varepsilon_Q = -\frac{Q}{L_Q} \frac{\partial L_Q}{\partial Q}. \quad (11)$$

这里比较的是不同自变量的**相对变化**对应的局部模型响应，不代表真实经济成本已经相同。质量评分 Q 的变动还必须限定在 B7 标尺与实验支持范围内。

2.7 质量提升 0.1 对应的等效参数量

固定训练数据量 D 。设原配置为 (N, D, Q) ，提高质量到 $Q' = Q + 0.1 \leq 1$ ；定义 N_{eq} 为在保持原质量 Q 的情况下，能够达到新质量配置预测 Loss 的等效参数量：

$$L_Q(N_{\text{eq}}, D, Q) = L_Q(N, D, Q'). \quad (12)$$

代入式 (6) 并整理，可得

$$N_{\text{eq}} = \left[\frac{(AN^{-\alpha} + BD^{-\beta}) \frac{g(Q')}{g(Q)} - BD^{-\beta}}{A} \right]^{-1/\alpha} \quad (13)$$

相应的等效参数倍率为 $M_N = N_{\text{eq}}/N$ 。式 (13) 仅在方括号内严格大于零时具有有限正解；等于零时仅能在 $N \rightarrow \infty$ 的极限达到目标；小于零时，固定 D 后，单靠扩张参数量无法达到该目标。实际工程上限尚未给出时，不应将数学外推的巨大 N_{eq} 解释为可实施的配置。

建议在论文中报告多个初始 (N, D, Q) 情景的倍率，并按“支持范围内 / 超出范围 / 不可达”分类；图 q2_07_quality_substitution 用于展示不同 D 下的倍率、条件参数区间与外推标识。正式倍率范围、外推情景数量及不确定性上下界均需从最终 q2_marginal_and_substitution.csv 中提取。

2.8 固定基础训练算力下的 $N-D$ 配置基准

使用经典近似成本关系 $C \approx 6ND$ ，其中 N, D 在物理计数单位下代入。若在本研究的十亿单位下表示为 N_B, D_B ，则

$$C = 6 \times 10^{18} N_B D_B \quad \text{FLOPs.} \quad (14)$$

固定质量 Q 与领域配比情景，且暂不计数据购置、清洗与质量提升成本时，共同正乘子 $g(Q)$ （以及给定情景下的配比乘子）不改变 N, D 的最优相对配置。因此基础优化可写为

$$\min_{N, D > 0} AN^{-\alpha} + BD^{-\beta} \quad \text{s.t.} \quad ND = K, \quad (15)$$

其中 $K = C/(6 \times 10^{18})$ ， N, D 均采用十亿单位。代入 $D = K/N$ ，对 N 求导并令其为零，得到无约束解析基准：

$$N^* = \left(\frac{\alpha AK^\beta}{\beta B} \right)^{1/(\alpha+\beta)}, \quad D^* = \frac{K}{N^*}. \quad (16)$$

如果要求 $N \in [N_{\min}, N_{\max}]$ 、 $D \in [D_{\min}, D_{\max}]$ ，则固定预算下 N 的可行区间为

$$\left[\max \left(N_{\min}, \frac{K}{D_{\max}} \right), \min \left(N_{\max}, \frac{K}{D_{\min}} \right) \right]. \quad (17)$$

可将无约束 N^* 投影到该区间，再由 $D = K/N$ 恢复相应的数据量；若可行区间为空则须报告不可行。此处的矩形约束仅确保 N, D 单独位于观测边际范围，并不保证联合配置实际训练过。上述计算仅构成**问题三**的

基础训练算力基准，不是考虑数据获取、质量提升和领域组成成本之后的完整最优资源配置。

2.9 跨来源验证与不确定性分析

跨来源实验分别报告无校准预测、目标源样本内校准和按模型族或来源分组留出的校准预测。样本内仿射拟合只能检验来源内曲线形状是否可通过平移与缩放近似，不能视为独立泛化表现。对于 B4、B5，模型迁移结果存在来源差异，论文应报告不利或不稳定的留出结果，不把一个校准系数解释为跨分词器或跨验证集的通用单位换算。

为评价参数稳定性，对 B1 的完整模型规模轨迹和 B7 的 (N, D) 质量组分别进行分组重抽样，并使用与正式模型一致的拟合目标逐次重估经典参数及质量系数。对于模型导出的 Loss、等效参数倍率与基本算力配置，将参数抽样传播到目标量。所得区间属于**固定模型、给定数据处理与重抽样假设下的条件参数区间**，不等于未来观测预测区间，也不包含未知共同生成机制、跨源口径差异、质量标尺误差、领域配比效应幅度及模型结构选择不确定性。

建议将主文结果组织为：经典律验证表、质量模型外层验证表、B4/B5 跨源留出表，以及 $E, A, \alpha, B, \beta, \kappa$ 的点估计和条件区间表。图 q2_09_parameter_uncertainty、q2_11_source_heldout、q2_12_nested_residuals 可分别展示参数、跨源与分层误差特征。

2.10 本问结论与问题三接口

本文建立了以经典参数量—数据量标度律为核心的经验预测模型，并在 B7 半合成质量实验尺度上引入可约项线性质量修正；进一步利用 A 组领域配比结果建立相对效应指数和条件化配比场景接口。经典模型在 B1 内部的留一规模及后段 Token 验证中具有较好的图示一致性；质量模型在 B7 分组验证中呈现优于无 Q 对照的预测表现；跨来源留出则显示了模型迁移的适用边界。

模型进一步给出了关于 N, D, Q 的局部偏导与弹性、质量提高 0.1 的等效参数量，以及固定基础训练算力下 N, D 的解析与矩形约束基准。但这些结果的可信范围由训练数据、质量标尺及来源兼容性共同决定。

向问题三交付时，主预测函数为

$$\hat{L}_{\text{main}}(N, D, Q) = E + (AN^{-\alpha} + BD^{-\beta})[1 + \kappa(1 - Q)], \quad (18)$$

其中 N, D 的单位均为十亿， Q 必须使用 B7_Q_score。问题一的质量评分不得未经标定直接输入。领域配比仅在显式指定 η_p 的条件情景中引入，并应保留来源、支持域和外推警告。问题三还须独立建立数据、质量提升与领域配比的成本及可行约束，不能将本问固定基础算力的解析基准直接当作完整资源优化结果。

附：正式定稿前需补入的工件与图表

- 经典律参数与留出成绩: results/q2_classic_parameters.csv、results/q2_classic_validation.csv。
- 质量选模与外层验证: results/q2_quality_model_comparison.csv、results/q2_quality_nested_metrics.csv。
- 跨来源留出: results/q2_source_heldout_metrics.csv。

- 条件参数区间:results/q2_classic_parameter_intervals.csv、results/q2_joint_bootstrap.csv。
- 等效资源与算力基准: results/ q2_marginal_and_substitution.csv、 results/q2_compute_optimal.csv。
- 领域配比接口与适用范围:results/q2_p_bridge_summary.csv、results/q2_interface_to_q3.json。
- 建议插入正式图:figures/q2_02_classic_holdout.pdf、q2_04_quality_model_comparison.pdf、q2_07_quality_substitution.pdf、q2_10_compute_optimal.pdf、q2_11_source_heldout.pdf。

本稿为可编辑的论文正文草稿，不含经队员确认的最终数值表，不代表正式提交版。