

问题三：算力预算约束下的大语言模型资源配置优化

用途：数学建模竞赛论文"问题三"正文底稿。本文必须与问题二的广义标度律、单位约定和证据边界保持一致。不得虚构附件或实验未支持的数值。图表位置保留占位符，后续用最终程序输出替换。

⚠ 所有最终数值均应从同一版程序输出表格自动填写。凡当前草稿中出现"约""接近""当前结果显示"等措辞，提交前应与最终 CSV/日志逐项核对；若程序最终值发生变化，以程序输出为准。



写作前必须统一的表述与修改注意事项

以下各条为本文写作的强制性规范，正文各节须严格遵守。

① 关于 $Q=1$ 的表述

不要写成"数据质量已经自然饱和"或"继续提高质量完全无收益"。应写成：当预算增大后，优化解达到本文设定的质量支持上界 $Q=1$ ，表明在当前质量尺度及实验支持范围内，进一步提高质量已无法继续被模型识别。 $Q=1$ 首先意味着质量约束成为活跃约束，并不等价于现实世界中的质量收益已经客观消失。

② 关于 10^{24} FLOPs 下预算利用率降低

不要写成"剩余算力没有价值"或"模型扩展已经停止"。当高预算下同时出现 $N=N_{\max}$ 、 $D=D_{\max}$ 、 $Q=Q_{\max}$ 时，应表述为：高预算情景下的低预算利用率主要来源于联合支持域边界，而非训练收益自然耗尽。

③ 严格区分支持域内优化和理论外推

正文中的主要最优配置必须以支持域内解为主。取消 N 、 D 或 Q 经验边界得到的结果只能称为"理论外推情景"或"边界外参考解"或"模型外推结果"，不得与支持域内最优配置混称为同等可信的"最优解"。

④ 关于 $Q_0=0.5$

$Q_0=0.5$ 是质量成本情景中的外生基准，不是附件数据直接估计得到的参数。正文必须明确这一点，并建议用多个 Q_0 值做敏感性分析，说明主要结论是否稳定。

⑤ 关于三种质量成本函数

指数型、幂型和对数型成本不应写成"三种真实成本规律"。更准确的表述为：为避免对未知质量提升成本作单一结构假设，分别采用指数型、幂型和对数型成本构造三类情景，以检验资源配置结论对成本函数形式的敏感性。

⑥ 关于质量增量成本

若采用 $C_Q=D[g(Q)-g(Q_0)]_+$ ，则 $Q \leq Q_0$ 时真实增量质量成本为 0。若绘图使用对数纵轴而无法显示 0，图注必须明确"零值采用绘图下限显示"，或直接从 Q_0 开始绘制成本曲线。

⑦ 关于领域配比

问题二已经说明 A 组数据能够支持领域配比的相对排序信息，但跨来源绝对效应幅度没有被充分识别。因此问题三中领域配比只能作为历史支持域内的相对优化或条件情景分析。不要直接声称已经识别出一个可在所有模型规模上普遍适用的 17 领域全局最优配方。

⑧ 关于 Q 与领域配比的关系

若质量指标 Q 本身已经由领域质量与配比信息构造，则联合优化 Q 与 p 时要防止重复计入同一效应。正文应说明二者是否独立，若无法确认，应把 p 的影响作为单独情景而非强行纳入主目标函数。

⑨ 关于 Bootstrap

Bootstrap 反映的是在当前模型结构、数据和估计流程固定条件下的参数与优化结果不确定性，不代表完整的现实世界预测不确定性。不要把非常窄的 Bootstrap 区间解释为"真实规律已经精确确定"。

⑩ 关于"全局最优"

若差分进化、多起点局部优化和网格搜索得到一致结果，可以称为"数值上稳定的候选最优解"或"在给定搜索域和模型下的数值最优解"。除非有严格数学证明，不要使用无条件的"全局最优"。

⑪ 关于单位

参数规模 N 和训练数据规模 D 必须沿用问题二的统一单位。若 N 、 D 以十亿参数和十亿 Token 表示，则基础训练成本换算必须显式写清，避免将 6ND 直接误当作物理 FLOPs。

⑫⑬ 关于问题二接口与模型结论

问题三中的 Q 必须使用问题二 B7 的 Q_{score} 尺度。问题一得到的质量指标若未完成尺度校准，不得直接代入问题二的质量修正函数。问题三本质上是"基于已拟合模型的资源配置优化"，结论应写成"模型预测下的最优配置"或"支持域内推荐配置"，避免写成现实世界中无条件成立的训练定律。

3.1 问题分析

问题二已经建立参数规模 N 、训练数据规模 D 与数据质量 Q 对验证集交叉熵损失 $Loss$ 的广义标度关系。问题三进一步要求在有限计算预算下确定参数规模、训练数据量、数据质量以及上下文长度之间的资源配置，并讨论领域配比调整可能产生的影响。

与仅考虑参数量和训练 Token 数的传统计算最优问题不同，本题还需要考虑数据质量提升和上下文长度增加所带来的额外计算开销。因此，本问的核心并不是单独最大化某一个训练要素，而是在总预算约束下平衡不同资源投入的边际收益与边际成本。

记问题二所得广义标度律为

$$L = F(N, D, Q; \hat{\theta})$$

其中 $\hat{\theta}$ 为问题二估计得到的模型参数。问题二的主模型可写成

$$L_Q(N, D, Q) = E + (AN^{-\alpha} + BD^{-\beta}) [1 + \kappa(1 - Q)]$$

该模型是在经典标度律

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}$$

基础上引入质量修正项得到的。由于 $Loss$ 越小表示模型预测性能越好，问题三可统一转化为约束优化问题

$$\min_{N, D, Q} F(N, D, Q; \hat{\theta})$$

并要求总计算成本不超过给定预算 C 。

- ❑ 需要强调的是，问题二对数据质量效应的识别主要依赖 B7 数据，而 B7 中质量变量具有半合成性质；因此问题三得到的 Q 最优配置应解释为在当前生成机制和模型假设下的资源配置结果，而不是对真实世界质量因果效应的无条件外推。

3.2 多源计算成本模型

将总计算开销分解为基础训练成本、质量提升成本以及长上下文附加成本：

$$C_{\text{tot}} = C_{\text{train}} + C_Q + C_{\text{attn}}$$

3.2.1 基础训练成本

按照题目采用的训练计算量近似关系，

$$C_{\text{train}} \approx 6ND$$

若 N 与 D 分别以物理参数数和物理 Token 数计量，上式可直接得到 FLOPs。若本文沿用问题二的单位，将 N 和 D 分别以十亿参数、十亿 Token 表示，记为 N_B 、 D_B ，则必须换算为

$$C_{\text{train}} = 6 \times 10^{18} N_B D_B$$

后文数值优化必须统一使用这一物理单位，避免数量级错误。

3.2.2 数据质量提升成本

真实世界中提高训练数据质量通常涉及筛选、清洗、去重、标注或重采样，但题目数据不足以唯一识别其成本函数。为避免作单一结构假设，分别采用指数型、幂型和对数型质量成本函数构造三类情景。

设质量成本函数为 $g(Q)$ ，以 $Q_0=0.5$ 为外生质量基准，则增量质量成本写为

$$C_Q = D [g(Q) - g(Q_0)]_+$$

其中 $[x]_+ = \max(x, 0)$ 。因此，当 $Q \leq Q_0$ 时不计额外质量提升成本；当 $Q > Q_0$ 后，不同函数 $g(Q)$ 描述质量进一步提升所需要的额外资源。

□ $Q_0=0.5$ 是为了构造中央情景而设定的外生基准，而非由附件直接估计。为检验结论对这一设定的依赖程度，后文应进一步改变 Q_0 进行敏感性分析。

3.2.3 上下文长度附加成本

若题目或程序采用注意力附加成本近似

$$C_{\text{attn}} = \eta ND L_{\text{ctx}}$$

则上下文长度 L_{ctx} 增大时，会占用更多计算预算。若该项与 C_{train} 的定义存在重叠，应在最终代码和论文中先完成成本口径核对，避免重复计费。

于是总预算约束可统一写为

$$C_{\text{train}}(N, D) + C_Q(D, Q) + C_{\text{attn}}(N, D, L_{\text{ctx}}) \leq C_{\text{max}}$$

若某一实验仅研究 N 、 D 、 Q ，而暂不考虑上下文长度，则令 $C_{\text{attn}} = 0$ ，单独在上下文敏感性分析中恢复该项。

3.3 联合支持域约束

若仅依据广义标度律进行无界优化，优化算法可能把 N、D、Q 推向远离原始实验数据的区域，使所谓"最优解"主要由模型外推决定，而非数据证据决定。

因此，根据问题二实验数据确定 N、D、Q 的经验支持范围。当前结果中采用的边界为

$$N \in [0.070542, 11.965825]$$

$$D \in [10, 299.893]$$

$$Q \in [0.1, 1]$$

其中 N、D 分别沿用本文统一的十亿参数和十亿 Token 单位。最终数值提交前应再次由程序读取原始数据自动核对上下界，避免手工抄写误差。

主优化模型写为

$$\begin{aligned} \min_{N,D,Q} F(N, D, Q; \hat{\theta}) \\ \text{s.t. } C_{\text{tot}}(N, D, Q, L_{\text{ctx}}) \leq C_{\text{max}} \\ N_{\min} \leq N \leq N_{\max}, \quad D_{\min} \leq D \leq D_{\max}, \quad Q_{\min} \leq Q \leq Q_{\max} \end{aligned}$$

⚠ 这里的矩形边界只保证每个变量分别处于观测范围内，并不意味着所有 N、D、Q 组合都具有同样强的联合数据支持。因此，在最终论文中还应结合"到最近观测点距离"或"到 B7 最近网格点距离"等指标评价联合外推程度。

正文中的主要结论均采用支持域内解。取消经验边界得到的解仅用于理论外推分析。

3.4 数值求解方法与可行性检查

联合质量成本后，目标函数与约束共同形成非线性优化问题。根据变量维数和当前函数结构，可采用结构化数值方法进行求解。

首先，在每一个预算 C 和每一种质量成本情景下构造可行域，并检查是否存在满足全部边界与预算约束的配置。若可行域为空，应报告不可行原因或最低预算缺口，而不能强行输出"最优解"。

对存在可行解的情景，可采用差分进化等全局搜索方法获得候选解，再使用 SLSQP 或 trust-constr 等局部约束算法进行精化。对于低维情景，可额外采用高密度网格搜索或枚举作为独立验证。

为保证数值结果可信，最终程序至少检查：

- 总成本是否满足 $C_{\text{tot}} \leq C_{\text{max}}$ ；
- N、D、Q 是否满足支持域约束；
- 最优解是否位于某一边界；
- 不同初值或随机种子是否得到相近结果；
- 全局搜索、局部优化与网格搜索是否一致；
- 是否存在明显更优的简单基准方案；
- 高预算结果是否主要由支持域边界决定。


若不同算法在给定搜索域中得到一致或近似一致的解，可称为"数值上稳定的候选最优配置"。

3.5 不同算力预算下的最优资源配置

图 3-1 给出了计算预算从 10^{19} FLOPs 增加至 10^{24} FLOPs 时，指数型、幂型和对数型三类质量成本情景下最优 N、D、Q 的变化轨迹。

【图 3-1：不同质量成本情景下 N、D、Q 随算力预算变化的三联图。此处插入最终程序图。】

整体上，最优配置呈现出明显的阶段性变化，可概括为：



在低预算 $C = 10^{19}$ FLOPs 附近，训练数据量已经接近支持域下界 $D=10$ ，说明有限预算首先受到基础训练规模约束。当前实验图显示，指数型成本情景下的最优质量约为 $Q^* \approx 0.58$ ，而幂型和对数型情景下最优质量接近 $Q_0=0.5$ 。最终论文应以程序导出的精确表格值为准。

这一结果说明，在总预算较小时，提高数据质量需要占用本可用于扩大 N 或 D 的计算资源，因此质量并非越高越优。不同质量成本函数在低预算区域会产生明显不同的最优质量选择。

随着预算提高至约 10^{22} FLOPs 的量级，当前三类成本情景的最优解均达到 $Q^*=1$ 。此后，成本函数差异主要通过 N 与 D 的重新配置体现，而不再表现为 Q 的差异。

□ 需要强调， $Q^*=1$ 表示最优解达到当前质量支持上界，并不能据此推断现实世界中继续提升数据质量已经完全没有收益。

当预算进一步增加至 10^{24} FLOPs 附近，三种成本模型的最优配置逐渐逼近

$$N = N_{\max}, \quad D = D_{\max}, \quad Q = Q_{\max}$$

因此三条最优轨迹在高预算区域趋于重合。这种重合主要由联合支持域边界造成，而不是证明三种质量成本函数在现实中等价。

3.6 最优质量水平的边际解释

为了说明不同预算下 Q^* 为什么发生变化，进一步比较固定 N、D 时提高质量的 Loss 收益，以及在总预算约束下提高质量造成的资源挤占代价。

记约束优化后的目标函数为 $\varphi(Q)$ ，则其边际变化可概括为

$$\frac{d\varphi}{dQ} = \underbrace{\text{提高质量引起的资源挤占损失}}_{\text{负效应}} - \underbrace{\text{提高质量带来的 Loss 改善}}_{\text{正效应}}$$

当内部最优点存在时，满足近似的一阶平衡条件

$$\frac{d\varphi}{dQ} = 0$$

这意味着在最优质量水平附近，继续提高质量所带来的预测性能改善，恰好被其占用预算导致的 N、D 缩减损失抵消。

当前结果显示，在 10^{19} FLOPs 的指数型成本情景下，两种边际作用在 $Q \approx 0.58$ 附近达到平衡，因此出现内部质量解；而幂型与对数型情景下，从 $Q_0=0.5$ 继续提高质量的边际资源代价已经较高，最优解停留在基准质量附近。随着预算增加，质量成本对 N、D 的挤占作用相对减弱，最优 Q 向上移动，并最终达到 $Q=1$ 的支持上界。

【图 3-2：固定 N、D 的质量收益与资源挤占代价比较。此处插入最终程序图。】

因此， Q^* 的变化不是优化器产生的偶然数值现象，而可以由“质量收益—资源成本”的边际平衡解释。

3.7 最优方案的计算成本结构

为分析算力究竟被分配到何处，将每个最优方案的总成本拆分为基础训练成本、质量提升成本和注意力成本三部分，并计算相应成本占比。

【图 3-3：代表性预算和成本情景下基础训练、质量提升、注意力成本占比堆叠图。】

当前结果显示，在代表性预算下，基础训练成本始终占据总成本的主体。低预算区域中，提高质量会明显挤占基础训练资源，因此部分成本模型选择维持 $Q \approx Q_0$ ；进入中等预算后，质量投入的相对价值提高， Q 逐步达到上界。

高预算阶段则出现另一种机制：由于 N 、 D 、 Q 已逐渐达到经验支持上界，即使总预算继续增加，模型也无法在支持域内继续把全部预算转化为更大的训练配置，因此预算利用率下降。

❏ 这一现象不能解释为“剩余算力无价值”，而应解释为“当前实验支持域已经不足以确定更高预算下的可靠最优配置”。

3.8 支持域边界与理论外推

为判断高预算平台究竟来源于真实收益饱和还是数据边界，进一步构造取消部分 N 、 D 经验上界的理论外推情景，并与支持域内最优解进行比较。

【图 3-4(a)：支持域内最优预测 Loss 与理论外推预测 Loss 随预算变化。】

【图 3-4(b)：理论外推解相对于支持域的最大外推倍数。】

当前结果显示，在 10^{19} 和 10^{22} FLOPs 等较低预算下，支持域解与理论外推解接近，说明最优配置仍主要位于数据可支持区域。

而在 10^{24} FLOPs 情景下，取消支持上界后，模型仍倾向于继续扩大 N 或 D ，并预测更低的 Loss；同时外推倍数显著增加。

支持域内解（主要结论）

以实验数据可靠支持的区域为准，作为正文主要结论。高预算下出现平台，说明现有实验数据已不足以可靠识别更高预算下的最优配置。

理论外推解（边界诊断工具）

取消经验边界后的外推结果，仅用于证明“预算平台来自哪里”，不替代支持域内结果成为新的主结论。外推解的可信度随外推距离增大而下降。

因此，高预算下支持域内结果出现平台主要说明“现有实验数据已不足以可靠识别更高预算下的最优配置”，而不能解释为 scaling law 本身已经自然停止改善。

3.9 上下文长度的资源挤占效应

在总计算预算固定时，提高上下文长度 L_{ctx} 会增加注意力相关计算，从而减少能够分配给参数规模、训练 Token 数和质量提升的预算。

若采用

$$C_{attn} = \eta ND L_{ctx}$$

则在其他变量相同时， L_{ctx} 越大，注意力成本越高。

当前上下文长度敏感性实验分别考察了 2^{11} 、 2^{12} 、 2^{13} 、 2^{15} 、 2^{17} 等代表性长度，并比较 10^{19} 、 10^{22} 和 10^{24} FLOPs 等预算水平。

【图 3-5：不同预算下预测 Loss 随上下文长度变化。】

结果显示，低预算情景下，模型本身已经处于明显的资源约束状态，因此上下文长度增加会较快挤占基础训练预算，使预测 Loss 上升；中等预算下该效应仍然存在但相对减弱；高预算支持域边界活跃后，曲线可能表现出较弱变化，但这不应解释为长上下文完全没有成本，而可能与 N、D、Q 已经受到边界限制有关。

③ 如果题目只给出了上下文长度的成本模型，而没有给出“更长上下文直接降低 Loss”的收益模型，则 L_{ctx} 不应被当作可以自由优化的能力变量。此时最稳妥的做法是把它视为外生任务需求，对不同 L_{ctx} 进行成本敏感性分析。

3.10 领域配比的条件优化

问题一已经建立训练领域配比与 Loss 之间的统计联系，问题二进一步构造了 A 源相对配比指数 $R_A(p)$ ，用于描述不同历史领域配方的相对优劣。

但现有数据只较可靠地支持历史配方之间的相对排序，尚不足以稳定识别领域配比效应在不同来源、不同模型规模下的绝对作用幅度 η_p 。

因此，不在问题三主模型中强行建立一个完全经验识别的四变量联合规律 $L(N, D, Q, p)$ ，而采用分层处理：

01	02	03
第一层：主优化模型	第二层：历史配方相对排序	第三层：条件情景分析
仅优化数据证据较充分支持的 N、D、Q。	在 A 源历史支持域内比较不同领域配方的相对排序。	若需要研究领域配比与 N、D、Q 的联合作用，则显式给定 η_p 构造条件情景。

条件情景模型写为

$$L_{scenario} = \left[E + \left(AN^{-\alpha} + BD^{-\beta} \right) (1 + \kappa(1 - Q)) \right] \exp[-\eta_p R_A(p)]$$

其中 η_p 不被解释为已经由跨来源数据精确识别的真实参数。

【图 3-6(a)：A 源历史相对配比指数 R_A 分布。】

【图 3-6(b)：不同 η_p 情景下最佳、中位和较差历史支持配方的条件预测 Loss。】

结果应表述为：领域配比能够在历史实验支持范围内改变条件预测 Loss 和配方排序，但其绝对收益仍依赖 η_p 的情景设定。因此领域配比结果主要用于说明“配方选择具有潜在价值”，而不能直接给出跨规模、跨来源普适的绝对性能增益。

3.11 解的支持程度与最近邻诊断

除了逐变量边界，还应检查每个最优解距离问题二真实观测点和 B7 网格点的距离。

将 N、D、Q 标准化后，可定义最优点 x^* 到数据点 x_i 的归一化距离

$$d(x^*, x_i) = \|z(x^*) - z(x_i)\|_2$$

其中 $z(\cdot)$ 表示按照各变量尺度进行标准化。

分别计算"到 B1 最近观测点距离"和"到 B7 最近网格点距离"，可以识别虽然落在矩形边界内部、但实际上远离真实联合观测区域的配置。

【图 3-7：不同预算、不同质量成本情景下最优解到 B1/B7 最近支持点的归一化距离。】

当前结果显示，高预算情景下部分距离趋近于零或受边界点控制，而中低预算情景存在一定距离差异。最终论文应结合具体数值说明哪些最优配置属于较强支持、哪些属于有限插值或边界附近结果。

3.12 不确定性与稳健优化

问题二已经通过 Bootstrap 获得参数不确定性样本。为把这种不确定性传播到问题三，不仅需要计算固定最优点的 Loss 区间，还应在每组参数样本下重新求解优化问题。

设第 b 次 Bootstrap 得到参数 $\theta^{(b)}$ ，则重新求解

$$x^{*(b)} = \arg \min_x L(x; \theta^{(b)}) \quad \text{s.t.} \quad x \in \Omega(C)$$

由 $\{x^{*(b)}\}$ 可以研究 N*、D*、Q* 的分布、边界活跃概率以及预算阶段转移的稳定性。

正文可同时比较名义解与 90% 分位稳健解。若采用风险厌恶目标，还可考虑

$$\min_x \mathbb{E}_\theta[L(x; \theta)] + \lambda \text{SD}_\theta[L(x; \theta)]$$

但 λ 必须具有明确风险解释，不能为了得到不同结果而任意选择。

【图 3-8：名义解与 90% 分位稳健解比较。】

当前 Bootstrap 结果表明，低预算情景的配置对参数扰动相对更敏感，而随着 Q=1 和 N、D 支持边界逐渐成为活跃约束，中高预算配置的结构更稳定。

□ 这种稳定性是"给定当前模型结构和数据流程"条件下的稳定性，并不代表真实世界训练结果具有同样窄的不确定范围。

3.13 基准方案比较

为了判断联合资源优化是否真正产生价值，应在相同预算、相同支持域和相同成本口径下，与若干简单策略进行比较。可设置以下基准方案：

- **经典 N-D 计算最优基准：**固定 Q 或不计质量成本，仅优化 N、D；
- **固定质量基准：**令 $Q=Q_0$ ，仅优化 N、D；
- **仅扩大参数规模；**
- **仅扩大训练数据量；**
- **联合 N-D-Q 优化；**
- **领域配比条件情景。**

定义优化收益

$$\Delta L = L_{\text{baseline}} - L_{\text{optimized}}$$

同时报告相对改善比例、成本利用率、基础训练/质量/注意力成本占比，以及最优变量变化。

③ 如果联合优化在部分预算下相对简单基准改善有限，应如实报告，而不需要为了体现模型复杂度夸大收益。

【表 3-1：不同预算下联合优化与基准策略比较。最终数字由程序导出后填写。】


3.14 预算路径与配置阶段

问题三最重要的结果不应只是一张"某预算最优配置表", 而应进一步给出预算变化时的配置路径。令

$$x^*(C) = (N^*(C), D^*(C), Q^*(C))$$

对连续预算网格求解后, 可以得到参数量、数据量、质量水平、成本份额以及活跃约束随 C 的变化。

如果程序结果显示活跃约束发生明确切换, 可以据此识别资源配置阶段:



⚠ 这些阶段必须由实际优化路径和活跃约束支持, 而不能为了叙述方便预先强行设定。

3.15 问题三结论

综合上述结果, 在当前广义标度律、质量成本情景和经验支持域下, 大语言模型的资源配置不存在一个与预算无关的固定 N:D:Q 比例, 而会随总计算预算发生结构性变化。

低预算阶段

基础训练成本占据主导, 训练数据量可能首先接近支持域下界, 提高数据质量会与参数量和训练 Token 数形成明显的资源竞争, 因此最优 Q 可能停留在基准质量附近或出现内部解。

中预算阶段

质量提升对基础训练资源的挤占效应相对减弱, 其边际收益逐渐能够覆盖额外成本, 最优 Q 向上移动并最终达到当前质量支持上界 $Q=1$ 。

较高预算阶段

参数规模 N 与训练数据规模 D 也逐渐接近经验支持上界。支持域内最优方案的预算利用率可能下降, 理论外推分析表明取消经验边界后模型仍可能预测扩大训练规模可以继续降低 Loss。

极高预算阶段

联合支持域成为主要限制, 必须区分支持域内配置与理论外推。高预算平台主要反映现有实验数据的支持范围不足, 而不能被解释为 scaling law 的自然终止。

上下文长度实验进一步说明, 长上下文会占用额外计算资源, 其影响在低预算情景下更明显; 若缺少上下文长度直接改善 Loss 的实证模型, 则应把上下文长度视为外生任务需求进行成本敏感性分析, 而不是无条件纳入能力最优化。

对于领域配比, 现有证据可以支持历史配方之间的相对比较, 但不足以精确识别跨来源、跨尺度的绝对效应幅度。因此本文将领域配比作为条件情景分析, 而不将其强行并入主模型形成一个表面完整但证据不足的 N-D-Q-p 四变量经验定律。

□ 上述结论是基于当前数据和问题二标度模型得到的"模型预测下资源配置规律", 其优势在于同时考虑训练规模、数据质量、上下文成本和模型外推风险, 并明确区分了经验识别结果与条件情景结果。

3.16 与问题四的接口

问题三向后续问题四提供以下可复用结果:

- 不同计算预算 C 下的支持域内候选最优配置 $N^*(C)$ 、 $D^*(C)$ 、 $Q^*(C)$;
- 不同质量成本函数下的资源配置路径及成本份额;
- 上下文长度 L_{ctx} 增加时的预算挤占关系;
- 高预算区域的支持域边界及理论外推风险;
- 领域配比的相对排序信息与条件情景结果;
- Bootstrap 参数样本下最优配置的稳健性结果。

⚠ 问题四若需要继续研究模型能力前沿或实际部署策略, 应优先使用问题三的支持域内配置作为基准; 若必须使用理论外推配置, 则应继续保留外推标记, 不得将其重新包装为已被实验验证的结果。

最终排版与图表取舍建议

问题三正文不建议把所有实验图全部塞入主文。主文优先保留以下图组:

- N、D、Q 随连续预算变化的三联图, 用于回答"资源如何配置";
- 成本占比堆叠图, 用于回答"预算花在哪里";
- 支持域内解与理论外推对比图, 用于回答"结论可信到哪里";
- 质量边际收益与资源挤占代价图, 用于回答"为什么出现当前 Q^* ";
- 若篇幅允许, 再加入上下文长度敏感性图。

Bootstrap 详细分布、最近邻支持距离、领域配比条件情景、名义解与稳健解的完整比较更适合放入附录。

最终正文的阅读逻辑建议保持为:

怎么配 → 为什么这么配 → 钱花在哪里 → 高预算为什么平台 → 结论可信到哪里