

问题四：技术演进分析与能力前沿预测

论文写作注意事项与正文草稿（待最终核验版）

供参赛队员核对、补数并统一全文后使用

2026 年 9 月 26 日

本稿的证据范围。本文依据已上传的比赛题目、23_q4_modeling_report.md、问题四准备/建模/最终验证源代码及最新结果图撰写。最新的 results/q4_final_*.csv/json 与实际运行日志没有随本轮附件上传，故不能确认最新版的精确回测和预测数值。下文所有 **【待核验】**、**【待填】** 不能直接留在参赛论文中；此前报告的数据不冒充最新数值。未采用《数据说明.pdf》的隐藏文字层。

第一部分 论文定稿之前要注意什么

一、先对照题目，明确哪些结论站得住

题目要求：使用 C1/C2 与 C3，使用 C4 中算力、数据量、开源权重等字段，对 C8 至少进行一项逐任务聚合分析；明确综合能力定义、开源与许可证筛选、pretrained 与 chat/finetuned 的分类、时间轴口径；量化规模扩张与非规模技术进步的贡献；利用 C5/C6 讨论 Loss 与 Benchmark 的映射和误差；预测算力放缓条件下未来 12/24 个月的开源能力前沿及不确定性。

现有工作的主线已经可写：数据筛选与去重—六项 Benchmark 综合能力及累计前沿—条件高分位模型与滚动选型—C8 任务异质性—历史端点的规模、时间代理与残差分解—Loss/Benchmark 桥接可识别性—随机纪录过程、历史回测与未来条件情景。

最关键的限定：目前没有因果识别出“纯技术进步贡献占比”。条件时间系数是在控制规模、模型类型等变量后的统计关联；端点分解残差很大，而且严格主口径下时间模型没有通过滚动预测选型门。可以报告规模分量、条件时间代理分量、未解释端点偏离的**描述性份额**，不能写成技术创新的真实因果份额。题目的“分离量化”要求在当前材料下仅得到描述性近似，若需要强因果结论，须补充可检验的识别假设、更多混杂变量或准实验设计；否则诚实陈述无法点识别的边界。

二、必须改掉的论文措辞

容易被质疑的写法	建议替换为
“时间系数是技术进步率”	“控制规模等因素后的条件时间代理系数，不能直接解释为因果技术进步率。”
“非规模技术贡献占 XX%”	“模型中的条件时间代理占观测端点变化 XX%，另有较大的未解释残差；非规模技术的因果份额不可由此识别。”
“未来分数落在 90% 置信区间内”	“在指定到达率、残差和算力情景下的条件 5%—95% 模拟分位区间，长期覆盖尚未校准。”
“Loss 可以预测综合能力”	“High 可比性小样本仅支持部分单任务局部桥接，六项综合分的统一映射未能识别。”
“停滞算力仍带来技术提升”	“即使规模漂移为零，保留模型到达及极值搜索机制时，累计模拟前沿仍可能上升；不作技术因果归因。”
“2026/27 年真实榜单将达到…”	“以 2025-03-13 为历史原点，对其后 12/24 个月作条件情景外推；不等于比赛时点的实测值。”

三、最新版本定稿前最需要查的三处

1. 真实回测窗口和预测跨度是否一致。最新 q4_final_validation.py 把预测跨度设为 30/60 天，却用 `min(cutoff+horizon, data.max_date)` 截断真值窗口。若最新真实记录截止于 2025-03-13，从 2025-02-01 预测 60 天就不足完整观察期。应报告每个情景的实际观测天数；主回测只保留完整窗口，或将模拟跨度同步缩短。重新核算全部与非重叠窗口的 MAE、更新场景 MAE、覆盖率、区间评分和相对持久性基准的改善。

2. 旧预测与修正预测必须统一。最终接口代码同时保留 formal_forecast（旧版）和 corrected_recalculation（新版）。正文只能选择**同一模型、同一假设、同一版本**的完整 P05/P50/P95 表，另一套仅作版本敏感性，不能把一版的中位数和另一版区间拼成最终结论。

3. “验证脚本已经写好”不等于“全部检查通过”。最新独立核验脚本设计了误差重算、嵌套选型时间顺序、尾部、单调性和分解恒等检查，但本次没有最终验证 JSON/CSV。请先确认实际运行结果、失败项与最新回测窗口核验，再在论文写“验证通过”。

四、其余四条易忽略的口径

- S_i 表示 0—100 的 Benchmark 分数, $Z_i = \text{logit}(S_i/100)$ 表示 **logit**。历史前沿若以“分”为单位, 必须写作 $F(t) = \max S_i$; 不能把 Z_i 当作分数前沿。模拟在 **logit** 空间进行时, 应逆变换后再报“分”。
- C8 的叶任务加权重构与 C8/C9 之间不同快照的差异是两个问题; 尤其 MATH 差异不能统称为重构误差。C3 跨年份历史序列不宜不加说明地混成同协议的能力真值。
- 开源标准需同时交代 Hub 可用性、SHA、许可名单、异常标记; 家族去重不得按最高分挑选。主时间轴是**榜单提交日**, 不能代替真实模型研发或发布日期。
- 原报告中的回测 MAE=3.15、经验覆盖率=88.9%、历史趋势下 12/24 月中位数=62.49/68.15 属于**前序版本**, 不得无核验地贴入最新版正式结果。

第二部分 问题四论文正文草稿

4.1 问题分析与研究框架

问题四要求利用开源大语言模型的历史评测信息, 分析规模扩张与非规模因素在能力演进中的表现, 并在训练算力增长放缓的条件下预测未来能力前沿。前几问的优化目标主要表现为交叉熵 Loss, 而本问所研究的多项 Benchmark 得分与 Loss 具有不同的评价对象和量纲。研究首先需要建立可复现的综合能力度量与统一的观察样本, 再分别解决条件能力建模、历史前沿建模、跨指标桥接和未来不确定性模拟。

为避免把给定规模下的高能力模型与历史上出现过的最高分混同, 本文定义两个对象: 条件能力上分位与累计历史能力前沿。前者刻画给定参数规模和模型层时能力分布的上部水平, 后者刻画截至给定日期的实测最高综合分。以历史滚动检验选择条件分位模型, 再结合候选模型到达机制和经验残差模拟未来累计前沿。另通过逐任务检验和端点分解讨论时间代理及非规模因素的统计表现, 通过 Loss—Benchmark 局部桥接限定前三问预测结果的适用范围。

4.2 数据、开源筛选与能力指标

本文采用 C1/C9 的榜单综合分和模型元数据作为主观察样本, 使用 C8 逐任务 JSON 分析评测维度差异; C4 的算力、参数量及开放权重字段用于标定算力增长情景, C3 用于跨年份口径敏感性; C5/C6 用于 Loss 和 Benchmark 的局部桥接。严格主口径要求模型在 Hub 可获得、未标记异常、具有非空 Model SHA, 并满足预先冻结的研究与复现许可名单。对同一 SHA 实体只保留首次提交记录; 基础家族优先由 Base Model 指定。pretrained/持续预训练与 chat/finetuned 分层分析, 衍生模型只作扩展。主时间轴采用 Leaderboard 提交日期, 并用 Hub 上传日期分析时间口径差异。

此前建模报告记录: C9 共 4576 条、36 列; 严格筛选后去重实体 1767 个, 用于核心时间模型、字段完整的 pretrained 与 chat/finetuned 样本 494 条、368 个家族。**【待核验】**定稿时须与最新版冻结样本清单逐项比对。设第 i 个模型的六项官方调整后得分分别为 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 的 B_{ik} , 综合得分定义为

$$S_i = \frac{1}{6} \sum_{k=1}^6 B_{ik}, \quad 0 \leq S_i \leq 100. \quad (4-1)$$

此前报告在 4492 条六项齐全记录上核对, 该等权平均与官方 Average 一致。令 $s_i = \min\{0.9995, \max(0.0005, S_i/100)\}$, 定义 **logit** 得分 $Z_i = \log[s_i/(1 - s_i)]$, 以缓和比例边界问题。基于得分的累计前沿定义为

$$F(t) = \max_{i: T_i \leq t} S_i, \quad (4-2)$$

其中 T_i 为模型首次有效提交日期。前沿的数学单调性只表示历史纪录不会随观察窗口扩大而下降, 不表示全部模型性能必然提高。




Figure 1: 严格开源核心层历史得分与累计前沿（提交日口径）。

4.3 条件上分位能力模型与滚动选型

为刻画给定规模下的高能力候选，取 $q = 0.90$ 的条件分位。令 $x_i = \ln N_i - \overline{\ln N}$ 为中心化参数规模， I_i 表示 chat/finetuned 层， t_i 为提交日期换算的年数。比较规模线性、规模二次以及含时间项的模型：

$$\begin{aligned}
 Q_{0.9}(Z_i|x_i, I_i) &= \beta_0 + \beta_1 x_i + \beta_c I_i, \\
 Q_{0.9}(Z_i|x_i, I_i) &= \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \beta_c I_i, \\
 Q_{0.9}(Z_i|x_i, t_i, I_i) &= \beta_0 + \beta_1 x_i + \gamma t_i + \beta_c I_i, \\
 Q_{0.9}(Z_i|x_i, t_i, I_i) &= \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \gamma t_i + \delta x_i t_i + \beta_c I_i.
 \end{aligned} \tag{4-3}$$

另设分位梯度提升树作为非线性候选。训练与评价采用基础模型家族等权重，逐折使用截止日前记录拟合，随后 60 天新提交记录作时间外推检验；对真实值 z 与预测分位 $\hat{q}$ ，采用 $\rho_{0.9}(z - \hat{q}) = \max\{0.9(z - \hat{q}), -0.1(z - \hat{q})\}$ 衡量 Pinball 损失。仅当最佳含时间模型相对最佳纯规模模型改善至少 5% 时才接受时间项。

此前冻结报告在严格核心主口径的七折滚动检验中，规模二次模型的家族等权 Pinball 损失为 0.08387，最佳含时间候选为 0.08696，未通过增益门。因此主能力条件分位采用纯规模候选。静态全样本回归出现正向时间系数，仍不构成其具有外推预测增益或因果技术解释的证据。【待核验】请以最终选型 CSV 核对模型规格和数值。

4.4 C8 逐任务变化与统计异质性

综合得分可能掩盖任务族之间的不同变化方向。对 C8 中 BBH、GPQA、MATH 和 MUSR 的叶任务，根据有效样本数加权重构任务族得分；IFEval 和 MMLU-PRO 保留其相应单任务得分。C8 叶任务重构与 JSON 内的任务族汇总是一种内部一致性检查，而将 C8 与 C9 的原始得分相比较属于跨快照检查，两者须分别报告。此前报告恢复 39 个任务、6 个任务族；其中 MATH 在不同快照之间存在不可忽略差异，不能作为“叶任务重构错误”解释。

对任务 j 的得分比例 s_{ij} 建立条件关联模型




Figure 2: 不同口径下条件分位候选模型的滚动损失和经验覆盖率。

$$\text{logit}(s_{ij}) = \alpha_j + \beta_j \ln N_i + \gamma_j t_i + \eta_j I_i + \theta_{j,e(i)} + \varepsilon_{ij}, \quad (4-4)$$

其中 $\theta_{j,e(i)}$ 表示评测签名固定效应。标准误按基础模型家族聚类，对多个任务的时间系数检验采用 Benjamini—Hochberg 校正。既有报告中，没有任务同时达到“时间系数为正”与校正后 $q < 0.05$ 的标准。本文据此不设统一的任务技术进步速度，而强调不同能力维度的时间相关性存在异质性。未发现稳健正向系数不等于证明现实技术没有进步。

4.5 规模与非规模代理的端点描述性分解

为讨论规模扩张对历史端点能力差异的解释范围，在 pretrained 与 chat/finetuned 两层分别选取历史起点与全期最终前沿，并利用可解释的规模—时间分位函数 $f(n, t)$ 构造两因素 Shapley 分解：

$$\begin{aligned} \phi_N &= \frac{1}{2}[f(n_1, t_0) - f(n_0, t_0) + f(n_1, t_1) - f(n_0, t_1)], \\ \phi_t &= \frac{1}{2}[f(n_0, t_1) - f(n_0, t_0) + f(n_1, t_1) - f(n_1, t_0)], \\ R &= (Z_1 - Z_0) - \phi_N - \phi_t. \end{aligned} \quad (4-5)$$

从而 $\Delta Z_{\text{obs}} = \phi_N + \phi_t + R$ ，各分量除以 ΔZ_{obs} 可得到**描述性比例**；因为不同项可相互抵消，比例允许为负或超过 100%。恒等式保证的是代数闭合而不是因果识别。残差 R 可包含架构、训练数据及领域配比、后训练、筛选差异、评测口径和遗漏变量等多个来源，不能将其全归为非规模技术创新。

最新版对不同起始日期分别重取历史前沿，并单列端点残差。图示显示两类模型层均存在较大且受端点选择影响的偏离变化；严格主口径下，时间模型又未通过滚动预测增益门。因此论文将 ϕ_t 表述为**条件时间代理分量**，而非已识别的“技术贡献占比”。如题目要求更强的技术贡献量化，目前应如实说明非规模技术因果份额在所给观测数据下不可点识别，并提出需要更细训练信息或可比较的准实验作为后续方向。

4.6 Loss 与 Benchmark 的局部桥接

前三问以交叉熵 Loss 为研究对象，问题四的多维 Benchmark 结果不由 Loss 唯一确定。本文对 C5/C6 中 High 可比性的同模型样本逐目标比较常数、线性、保序和 Logistic 映射，按逐点留一 RMSE 评价，并要求非恒定映射相对常数基准改善至少 5%，且留一秩相关方向合理；Medium 可比性样本仅用于敏感性分析。

已有报告指出，High 可比性锚点仅有 7 个，六项综合得分的最佳非恒定映射未优于常数基准；BBH、IFEval、MATH 仅呈现各自支持区间内的局部映射证据。由此，不将问题一至三的 Loss 数值直接换算成




Figure 3: 两层模型在不同起始日期下的端点分量与偏离变化；该图不表示技术因果贡献。

未来六项综合能力，更不让局部桥接承担本问主预测。若将单任务局部映射用于辅助情景，应注明其 Loss 支持范围、留一误差、评测协议及小样本不确定性；超出支持范围不作数值推广。

4.7 累计前沿的随机纪录过程

设 $F(t)$ 为截止 t 的历史累计最高综合能力；持久性基准为 $\widehat{F}(t+h) = F(t)$ 。为同时刻画未来模型数量与能力变化，设置窗口内候选模型到达数 $K_h \sim \text{Poisson}(\lambda h)$ ，候选模型的参数规模按历史经验分布及规定漂移采样，综合能力由条件上分位模型与经验残差生成。第 b 条模拟路径的累计前沿为

$$F^{(b)}(t+h) = \max \{F(t), S_1^{*(b)}, \dots, S_{K_h}^{*(b)}\}, \quad (4-6)$$

其中 $S_k^{*(b)}$ 为逆 logit 后的百分制得分，故 F 的量纲始终为“分”。此式是候选到达和极值搜索的条件模拟，而非真实技术进步定律。为检查同一家族多次出现及残差重复抽样带来的极端值偏差，另比较家族泊松与家族负二项—尾约束候选，但是否替换主模型只依据预先确定的历史回测指标，而非凭情景曲线是否“更合理”主观选择。

4.8 历史滚动回测与模型选择

按照历史截止日建立外层时间回测，并仅使用外层截止日之前的数据进行内部模型规格选择。比较持久性、原家族平衡随机纪录过程和两个家族到达候选，同时报告全部完整窗口、非重叠 60 日窗口以及真正发生纪录更新的子集。对前沿预测计算 MAE，并对模拟的 P05/P95 区间统计实际覆盖、平均宽度及区间评分；对外层截止日作成组 Bootstrap，减少重叠窗口造成的独立性错觉。

已提供的最新回测图显示，原随机纪录过程在绘出的历史情景中相对持久性有明显的 MAE 降低；不同家族候选在点预测与区间表现之间存在权衡。**【待核验】**最新代码中的真实观察终点可能截断了若干 60 日窗口，因此以下表格必须先依据完整窗口重新计算，不能照搬原图数值。

模型	完整窗口数	MAE (分)	更新情景 MAE (分)	90% 经验覆 盖率	平均区间评 分	非重叠 60 日 MAE (分)
持久性	【填】	【填】	【填】	【填】	【填】	【填】
最终入选纪 录过程	【填】	【填】	【填】	【填】	【填】	【填】
家族泊松	【填】	【填】	【填】	【填】	【填】	【填】
家族负二项 +尾约束	【填】	【填】	【填】	【填】	【填】	【填】




Figure 4: 新版回测误差及区间诊断。正式稿应采用截断窗口修正后重画的最终图。

短期滚动窗口中的经验覆盖不能自动证明长达 12/24 个月的预测分位区间已校准，故后续将区间称为**条件情景模拟区间**而非带有保证的长期置信区间。

4.9 算力增长放缓情景与 12/24 个月预测

根据 C4 中历史开放权重语言模型的训练算力与参数量关系建立经验映射，换算未来假定算力增长为对数规模漂移。算力数值包含观测与估计混合项，所得到的漂移仅用于设定条件情景而非识别算力的因果效果。将历史算力增长趋势作为参照，分别设定其 1、0.5、0.25 与 0 倍的未来规模漂移；保持其他机制在各情景间可比，逐情景运行模拟并提取累计前沿 P05/P50/P95。进一步改变模型到达率、历史残差尾部 and 算力—参数映射，以评估预测对机制假设的敏感性。

本研究的历史预测原点固定为 **2025-03-13**，12/24 个月终点为 **2026-03-13** 与 **2027-03-13**；这是对给定历史数据截点的条件外推，不是本届比赛时点的最新实测能力预测。**【待填】**请从唯一选定模型的最新版正式预测 CSV 填入下表，并核对 P05 不大于 P50 且 P50 不大于 P95、累计前沿不得小于原点观测最高分。

规模漂移对应的算力情景	12 个月 P05 / P50 / P95 (分)	24 个月 P05 / P50 / P95 (分)
历史趋势 1.00×	【填入同版本三数】	【填入同版本三数】
中度放缓 0.50×	【填】	【填】
强放缓 0.25×	【填】	【填】
零规模增长 0×	【填】	【填】

从已有情景图看，在相同到达及残差假设下，规模漂移减小通常对应更低的模拟前沿；即使规模漂移为零，只要仍有新候选模型到达且对候选能力取累计最大值，模拟前沿仍可能上升。该现象是到达与极值搜索机制的结果，不能直接等同于在真实算力停滞下发生了技术创新。




Figure 5: 算力增长情景与累计前沿（前序版本图）。若改用最新版模拟结果，应替换为同一最终版本绘制的图。

4.10 稳健性、局限与结论

本文通过严格/宽口径、不同模型层、提交日期/上传日期、C8 完整评测签名、分解起点、模型到达强度、残差尾部和计算—规模映射开展多维敏感性检验。然而，榜单提交样本具有选择性，提交时间与模型研发时间并不等价，跨年度评测协议可能变化；C4 训练算力包括估计值，C5/C6 High 可比性锚点很少，未来候选模型到达和能力残差机制并无长期稳定性保证。尤其 24 个月预测跨度明显超过已进行的短期历史回测，模拟区间不得写成已通过未来真实数据检验的覆盖保证。

综上，本文给出了开源模型综合能力与累计前沿的可复现定义，并利用时间滚动检验选择条件能力分布模型。C8 的逐任务结果显示能力维度变化具有异质性，端点分解揭示参数规模与条件时间代理不能充分解释历史领先模型的得分差异；在当前观察性数据下，**无法将未解释残差或时间代理唯一归因为非规模技术进步**的因果贡献。Loss—Benchmark 数据仅支持有限单任务局部桥接，故长期主预测直接基于历史 Benchmark。修正并核验完整回测窗口后，所选随机纪录过程可为不同算力增长、模型到达和残差延续假设下的能力前沿提供**条件情景参考**，但不应替代对未来模型、技术与评测协议变化的实际观测。

第三部分 交稿前的最终替换表

内容	以哪个真实结果为准	必须核对的点
样本与口径	q4_cohort_summary.csv; q4_filter_contract.json	SHA 去重、许可、时间、模型类型
条件分位选型	q4_quantile_selected_models.csv	严格主口径、7 折、5% 门槛
C8 与多重检验	q4_c8_task_time_effects.csv	叶任务、签名与 BH 校正
端点分解	q4_final_decomposition_sensitivity.csv	恒等式闭合、端点敏感性、非因果
Loss 桥接	q4_bridge_decisions.csv	High 样本、逐维 LOO、支持区间
最新回测	q4_final_record_backtest.csv、 q4_final_record_metrics.csv	先修正截断窗口再填全部指标
正式未来预测	q4_final_closure_interface.json 与唯一正式预测 CSV	旧版与重算版只选同版本一套
完整验收	q4_final_independent_verification.csv 及运行日志	确认检查实际通过并增加窗口完整性检查

投稿前操作：删除所有【待核验】【待填】及本部分工作提示，统一整篇论文图号、公式编号、变量量纲和引用；将最终图指向正式结果工件；在附件或复现说明中保留数据口径、脚本及种子。建议由参赛队员亲自确认问题四对“非规模技术进步贡献占比”的回答深度，勿把代理变量当作因果证明。

本稿材料来源：已上传比赛题目（问题四及附件要求）、23_q4_modeling_report.md、q4_prepare.py、q4_modeling.py、q4_final_validation.py、q4_final_figures.py、q4_final_independent_verify.py 和本次已提供的历史前沿、条件分位、端点分解、回测与前沿情景图。最新机读结果及完整运行日志未提供，本稿没有虚构其精确数值。